Szentimentanalízis Projekt Jelentés

Körtvélyesi Dániel, Jánó Róbert

2026. november 9.

Kivonat

Ebben a projektben különböző megközelítéseket alkalmaztunk szöveges vélemények szentimentanalízisére. Ez a jelen feladat esetében azt jelenti, hogy egy-egy vélemény szövege alapján meg kell határoznunk, hogy az adott vélemény pozitív vagy negatív hangvételű. A projekt célja ezen feladat különböző megoldási módszereinek összehasonlítása; pontosabban összehasonlítottuk a hagyományos gépi tanulási módszereket a modern nyelvi modelleken alapuló módszerekkel. A projekt során az alábbi modelleket dolgoztuk ki: One-hot encoding + Classification, BERT embedding + Classification, Standard text classification pipeline, Fine-tuned BERT, valamint Base BERT + Freezer modell. A finomhangolási kísérletek során három különböző mélységű modellt tanítottunk és mentettünk a HuggingFace platformra.

Az adatforrás egy nagy méretű Amazon termékértékelési adatbázis volt, melyből egy kiegyensúlyozott, előfeldolgozott mintát hoztunk létre. A projekt folyamán próbálkoztunk két különböző előfeldolgozási ötlettel is, melyeket 2 modell esetében össze is hasonlítottunk egymással. Előfeldolgozás után a kidolgozott modellek létrehozása, és a különböző módszerek teljesítményének részletes kiértékelése következett.

1. Bevezetés és adathalmaz

A szentimentanalízis célja, hogy szöveges adatok alapján automatikusan megállapítsuk, hogy az adott vélemény pozitív vagy negatív. Projektünk célja, hogy különböző gépi tanulási és természetes nyelvfeldolgozási (NLP) technikákat alkalmazzunk és hasonlítsunk össze egy valódi, nagy volumenű szöveges adathalmazon, mely esetünkben egy, a kaggle platformon közzétett, amazonos termékértékeléseket tartalmazó adathalmaz.

1.1. Az adathalmaz bemutatása

Az adathalmaz 4 millió Amazon termékértékelést tartalmaz, amelyből a projekt során két kisebb, 1– és 10%-os mintát használunk. Az adathalmaznak három oszlopa van: a vélemény címe (title), a vélemény teste (comment), valamint a vélemény érzelemcímkéje (label), amely pozitív vagy negatív lehetett. A 4 millió adatsor eredetileg is szét van választva 90-10%-os arányban tanuló adatnak és kiértékelő adatnak. A teljes adatbázist mindkét szegmensére igaz, hogy a sorok pontosan fele negatív- és pontosan fele pozitív töltetű.

Az adatbázis nagyon kevés hiányzó adatot tartalmazott, így mintavételezéskor hiányzó adatokkal rendelkező sorokat egyszerűen nem vettünk be. A mintavételezés random sample

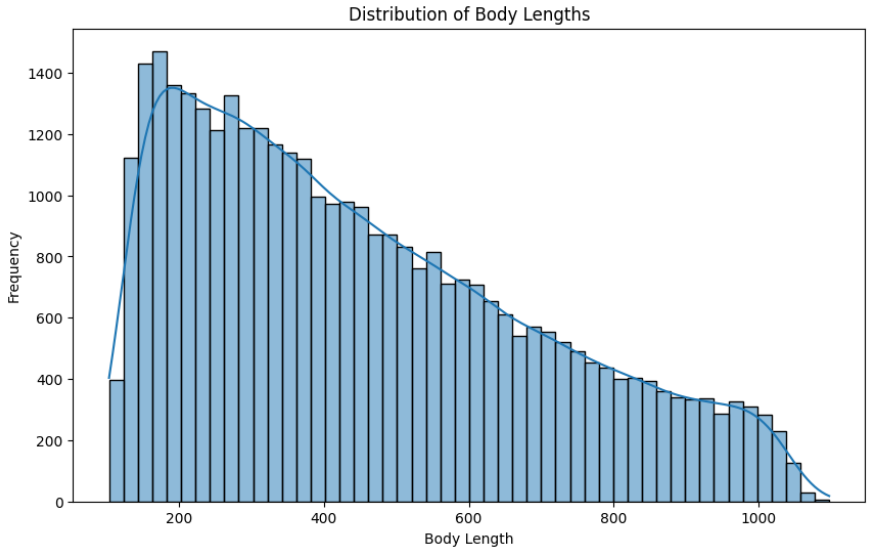
használatával történt, ami alapján nem meglepő, hogy a vélemények érzelemeloszlása kiegyensúlyozott volt a mintáinkban is, azaz a pozitív és negatív példák megközelítőleg azonos számban szerepeltek. Ez különösen előnyös, mivel így nem volt szükség osztálykiegyenlítési technikákra.

2. Adatelőkészítés és feldolgozás

A projekt implementációja a Google Colab felületen valósult meg. Az adathalmaz mintavételezése után a kapott mintákat Google Drive-ra mentettük, így minden runtime esetén első lépésként csatlakoztattuk a Google Drive-ot, és onnan töltöttük be az Amazon értékeléseket tartalmazó adatfájlt. Az előfeldolgozás során az alábbi átalakításokat végeztük el:

- a cím és a komment mezőket egyesítettük egy új oszlopba ("body");
- a címkét bináris formátumra alakítottuk: 1 = pozitív, 0 = negatív;
- eltávolítottuk az URL-eket, email címeket és különleges karaktereket;
- minden szöveget kisbetűssé alakítottunk és eltávolítottuk a felesleges szóközöket.

Ezt követően megvizsgáltuk a rekordok szöveghosszát. Az átlagos hossz 454 karakter volt, de sok bejegyzés meghaladta az 512 karakteres BERT input limitet, egyes rekordok pedig az 1024 karaktert is túllépték. Az **1. ábrán** látható az 1%-os minta véleményeinek karakterhossz szerinti eloszlása, amely az ábra alapján lognormálisnak tűnik. Ezért egy második előfeldolgozott adattáblát is létrehoztunk. Azzal is kísérletezni akartunk, hogy a cím kétszeres hozzáadása a véleményhez befolyásolja-e a modellek teljesítményét; így a címet beszúrtuk a vélemény elé és után is, így hozva létre a "body" oszlopot. Ezek után külön oszlopokba eltároltuk minden vélemény esetén az első 512 karaktert ("first"), az utolsó 512 karaktert ("last") és a középső 512 karaktert ("middle"). Később minden szegmens külön-külön került modellezésre, és a szegmensek alapján kapott eredményeket átlagoltuk egy-egy modell alapján; így kezelve annak bizonytalanságát, hogy a szöveg bármelyik része tartalmazhat meghatározó információt.



3. Hagyományos gépi tanulási modell

A szövegeket szóhatár-alapú szeleteléssel tokenizáltuk, majd egy angol nyelvű stemmer segítségével szótöveztük. Miután megállapítottuk a leggyakoribb szavak listáját, One-Hot Encoding bináris reprezentációt alkalmaztunk, amely során minden véleményt egy nagydimenziós, 0 és 1 értékeket tartalmazó vektorrá alakítottunk. Ez azt jelenti, hogy minden komment esetén létrehoztunk egy 768 karakteres bináris vektort, aminek egy helye aszerint 1-es vagy 0-s, hogy az adott helynek megfeleltetett gyakori szótő benne van az adott kommentben vagy sem. Ez egy egyszerű vektorizálási vagy embedding módszer, ami nem vesz figyelembe semmilyen pozicionális vagy szemantikus kontextust.

A kapott vektorok dimenziója az egyedi tokenek számával arányos, ami túlságosan nagy és ritka mátrixokat eredményezett. Ezért a dimenziók számát Truncated SVD (Singular Value Decomposition) segítségével 300-ra csökkentettük. Ez a lépés jelentősen javította a számítási hatékonyságot anélkül, hogy az információtartalom jelentős részét elvesztettük volna.

Az így kapott tömörített jellemzőkre logisztikus regressziós osztályozót tanítottunk. A modell teljesítményét a predikciók alapján mértük, és a következő metrikákat kaptuk:

Modell	**Pontosság**	**ROC AUC**	**F1-score**
One-Hot Encoding + Classification	91.2%	96.7%	91.2%

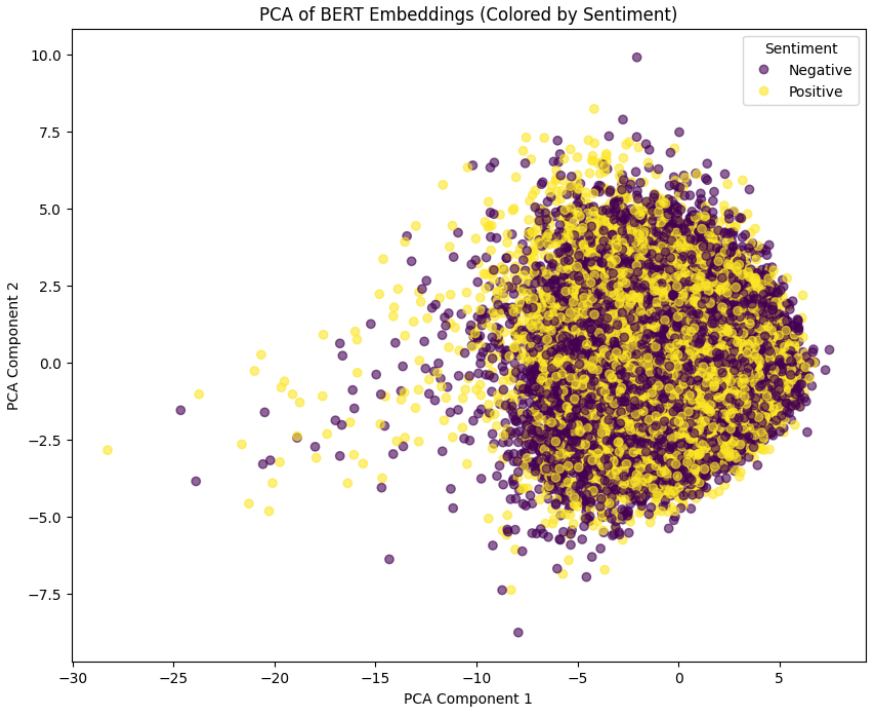
Ez a modell baseline-ként szolgált a komplexebb transformer alapú modellekhez való viszonyítás során. Meglepő módon a hagyományos NLP + logisztikus regresszió kombinációja erős teljesítményt mutatott, a gyors betaníthatósága és egyszerűsége mellett is.

4. BERT beágyazások + logisztikus regresszió

A BERT (Bidirectional Encoder Representations from Transformers) egy előre betanított nyelvi modell, amelyet az angol nyelv kontextusfüggő reprezentációinak kinyerésére használtunk. A szöveges bemenetekből a CLS tokenhez tartozó embedding vektort nyertük ki, amely a teljes szekvencia összefoglaló reprezentációját adja.

Az egyes véleményekhez így egy 768-dimenziós jellemzővektort kaptunk. A dimenziók csökkentése érdekében főkomponens analízist (PCA) alkalmaztunk, amely segítségével a jellemzők számát 100-ra szűkítettük. A cél az volt, hogy megtartsuk az információtartalom nagy részét, miközben javítjuk a számítási hatékonyságot és csökkentjük a túltanulás esélyét.

Ezen dimenziócsökkentés során megvizsgáltuk, először is, hogy mennyi információt vesztettünk. Ezen vizsgálat eredménye a 97.2%-os információ-megőrzési érték volt. Két- és háromdimenziós vizualizációs vizsgálatot végeztünk a kapott reprezentációs vektorok főkomponensek mentén történő megjelenéséről. A **2. ábrán** látható 2 dimenziós vizsgálathoz hasonlóan azt kaptuk, hogy 2-3 dimenzióban még nincs geometriai különbség az érzelmi klaszterek között, ami természetes; mivel mindkét osztályban jelentésben nagyon hasonló termékleírások találhatóak.



Az így kapott tömörített embedding vektorokat logisztikus regresszióval osztályoztuk. A modell az alábbi metrikák szerint teljesített:

BERT Embedding + Classification	**Pontosság**	**ROC AUC**	**F1-score**
Cím + komment	88.1%	94.7%	88.2%
Cím + komment + cím 3 részben	86.5%	93.6%	86.5%

A módszer gyors, mivel nem igényel újratréningelést a BERT modellen. A tanítás kizárólag a logisztikus regresszióra korlátozódik.

5. Standard szövegklasszifikációs pipeline

A Transformers könyvtár „pipeline” eszközét használtuk egy egyszerű, előre betanított szentimentanalízis pipeline kiértékelésére. A modell a HuggingFace által publikált „distilbert-base-uncased-finetuned-sst-2-english” volt, amely nem igényelt külön tanítást.

A három részre lebontott predikciók során minden egyes inputra három valószínűségi kimenetet kaptunk. Ezeket az értékeket összeátlagoltuk, majd az így kapott kompozit érték alapján határoztuk meg a végső osztályt (pozitív vagy negatív).

A pipeline kimenetének kiértékelése során a következő eredményeket kaptuk:

Standard klasszifikációs pipeline	**Pontosság**	**ROC AUC**	**F1-score**
Cím	80%	-	-
Komment	88%	-	-
Cím + komment	89.8%	95.8%	89.8%
Cím + cím + komment	91%	-	-
Cím + komment + cím 3 részben	89.5%	96.1%	89.8%

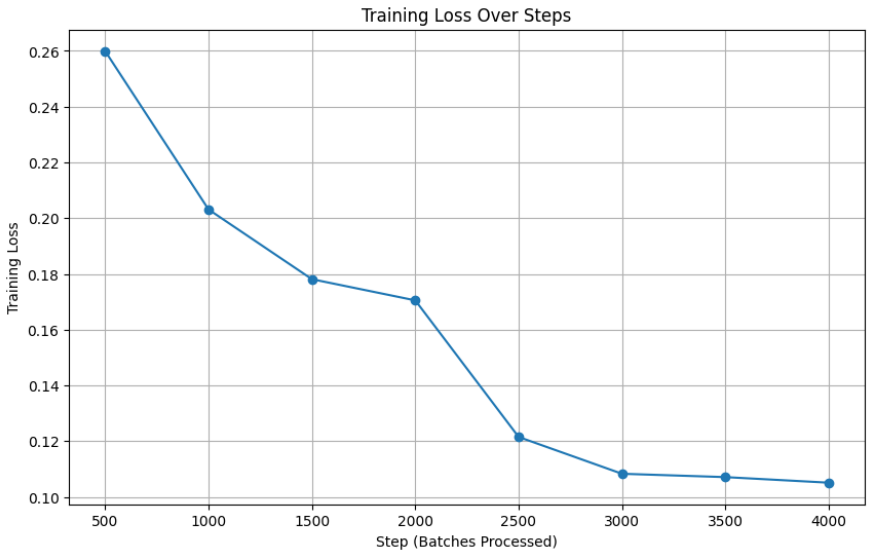
Ez a megközelítés meglepően jó eredményeket adott annak ellenére, hogy nem történt semmiféle finomhangolás. Ez a pipeline hasznos baseline-ként szolgált a további, összetettebb modellekhez való viszonyításban.

6. Finomhangolt DistilBERT modell

A következő modellünk a DistilBERT volt, amely egy kompaktabb és gyorsabb változata az eredeti BERT-nek, miközben megtartja annak teljesítményének nagy részét. A HuggingFace AutoTrain eszközt használtuk a finomhangolás automatizálására.

A bemeneti adatokat a HuggingFace text-classification‘pipeline-hoz illesztettük, majd a distilbert-base-uncased‘modellt finomhangoltuk egy bináris osztályozási feladatra. A cím és komment összevont szövegmezője képezte a bemenetet.

A finomhangolás két epochon keresztül zajlott, ‘batch size- 16 mellett, miközben a ly-earning rate‘automatikusan lett meghatározva. Az osztályozó fej az eredeti modell része maradt, azaz nem történt architektúramódosítás. A tanítási hiba értékét nyomon követve látható volt, hogy a tanítási görbe a tanítás kétharmada körül ellaposodott. Ezt a jelenséget megtekinthetjük a **3. ábrán** is.



A modell teljesítménye pontosságot és F1-scoret tekintve egyaránt 95.3%.

A finomhangolt DistilBERT modell gyors és hatékony volt, miközben elérte a logisztikus regressziós modellekhez képest kissé jobb teljesítményt. Ez a modell a projekt során referenciaértékként szolgált a mélyebb finomhangolású BERT architektúrákhoz képest.

Három különböző nagyságú finomhangolást végeztünk és mentettünk HuggingFace-re. Először 3000 adatsort használtunk a finomhangolásra, majd 18 ezret, végül pedig 36 ezer adatsort. A három modell között kiértékelés során a harmadik teljesített a legjobban, ennek eredményei láthatóak fennebb.

7. BERT + Freezer

A projekt legerősebb modelljei teljes tanítási tervek szerint tanított BERT osztályozók voltak. Ezen a modellek lehetővé tették, hogy külön kezeljük a BERT nyelvi modellt és az azt követő osztályozó fejet, így nagyobb kontrollt kaptunk a tanítási folyamat fölött.

Az alapmodellre egy 4 rétegű sűrű fejet tettünk, aminek rétegei sorrendben egy dropout-, egy lineáris-, egy ReLU- és egy második lineáris réteg volt.

A modell két fő szakaszban lett tanítva:

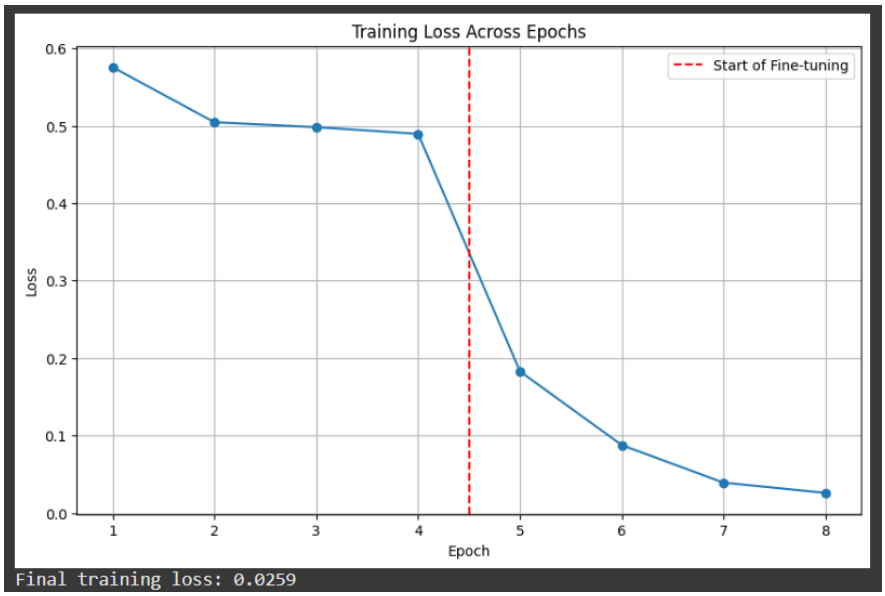
- Az első szakaszban a BERT rétegeket lefagyasztottuk, és kizárólag az újonnan definiált, 4 rétegű sűrű osztályozó fejet tanítottuk.
- A második szakaszban feloldottuk a BERT rétegek zárolását, és az egész modellt finomhangoltuk.

Ezen tanítási séma szerint három különböző modellt tanítottunk be aszerint, hogy az előbb leírt két tanítási szakaszban mennyi epoch-nyit tanítottuk a modellt. A következő táblázat ezen három modell teljesítményét mutatja az eredeti adathalmaz 10%-át kitevő tesztadaton.

Freeze	**Unfreeze**	**Pontosság**	**ROC AUC**	**F1-score**
3 epoch	2 epoch	95.5%	99%	95.5%
4 epoch	6 epoch	95.2%	98.4%	95.2%
4 epoch	4 epoch	94.8%	98.7%	94.8%

A modellt PyTorch-ban valósítottuk meg, ‘AutoModel.from_pretrained()segítségével betöltöttük a ‘bert-base-uncased‘modellt, majd erre építettük a saját architektúránkat. A veszteségfüggvény CrossEntropyLoss‘volt, az optimalizálást pedig ‘AdamW‘algoritmussal végeztük.

A kimenetek osztályozása a CLS token embedding alapján történt, amelyet teljesen új, sűrű rétegeken keresztül továbbítottunk. A modellek tanítása során nyomon követtük a tanítási görbe alakulását. A **4. ábrán** ezen tanítási görbét láthatjuk a 4+4 epochos modell esetében.



Ez a modell minden korábbi megközelítést felülmúlt, és a projekt csúcspontját jelentette mind teljesítményben, mind technikai mélységben és tanulási időben.

8. Eredmények és következtetés

Az alábbi táblázat összefoglalja a különböző modellek legjobban teljesítő verzióinak kiértékelési metrikáit:

Modell	**Pontosság**	**ROC AUC**	**F1-score**
One-Hot + SVD + LR	91.2%	96.7%	91.2%
BERT embedding + LR	88.1%	94.7%	88.2%
Standard pipeline (DistilBERT)	89.8%	95.8%	89.8%
Finomhangolt DistilBERT	95.3%	-	95.3%
BERT + Freezer	**95.5%**	**98.7%**	**95.5%**

A kísérletek alapján megállapítható, hogy bár a klasszikus logisztikus regressziós modell is meggyőző eredményeket produkált, a transformer alapú modellek – különösen a teljes mértékben finomhangolt BERT – lényegesen magasabb prediktív teljesítményt biztosítottak.

Az eredmények alapján egyértelműen látszik, hogy a komplexebb modellek, különösen a BERT + Freezer architektúra, lényegesen jobb teljesítményt nyújtanak, mint az egyszerűbb embedding vagy one-hot + SVD + LR megoldások. A ROC AUC értékek különösen magasak, ami arra utal, hogy minden klasszifikációs küszöbértéket figyelembe véve a modellek jól különböztetik meg a pozitív és negatív véleményeket.

A standard pipeline és a DistilBERT modellek gyorsak és könnyen alkalmazhatók, így ideálisak gyors kísérletezésre és baseline teljesítmény meghatározására. A BERT fine tuning alapú megközelítés kompromisszumot jelentett az implementálási és számítási idő, illetve a teljesítmény között – nem meglepően, ez az egyik legnépszerűbb megoldási módszer kisebb feladatok elvégzésére.

A modellek tanulási görbéi is értékelésre kerültek. A Freezer modell esetében jól megfigyelhető volt a folyamatos javulás – különösen látványos volt, hogy az első head training és az első teljes modell training epochok voltak a leghatásosabbak.

9. Fejlesztési lehetőségek

Esetleges jövőbeli munkák során érdemes lenne:

- Érdekes lehet tovább vizsgálni a vélemények hosszának lognormalitását, mivel a véleményhosszak ismert eloszlása esetén gyakorlati alkalmazásokban számolni lehetne a vélemények hosszának várható értékével és szórásával.

- Annak ellenőrzése, hogy egy sokkal egyszerűbb, akár csak egy lineáris réteggel rendelkező fej használatával is hasonlóan jó teljesítményt érhetünk el a BERT + Freezer modell esetén.

- A BERT embedding vektorok többdimenziós vizsgálatával azon kérdés elemzése, hogy geometriailag hogyan jelennek meg az egyes csoportok jelentésbeli különbségei; mely quantization szempontjából lenne jelentős.
- Számításhatékonysági módszerek (pl. LoRA) kipróbálási, és hatékonysági javítások eredményeként a modellek nagyobb méretű adathalmazon történő tanítása.

Összességében a projekt megvalósítása értékes betekintést nyújtott a nagy nyelvi modellek és a hagyományos szöveges gépi tanulási modellek működésébe, gyakorlati alkalmazhatóságába és korlátaiba. A különböző megközelítések összevetése megmutatta az LLM-alapú megoldások fontosságát olyan feladatokban, ahol célunk a magas szintű pontosság és a nyelvi mintázatok mélyebb megértése.

10. Hivatkozások

- Google Drive mappa kimentett modellekkel és adatokkal: `https://drive.google.com/drive/folders/1f9jkRfF1_KK_H6rzRWl-6HNWg2tf8rG5?usp=sharing`
- Kaggle Amazon Reviews Database: `https://www.kaggle.com/datasets/kritanjalijain/amazon-reviews`
- HuggingFace Transformers: `https://huggingface.co`
- Megosztott tananyag LLM modellekről: `https://drive.google.com/drive/folders/1WOlauJzTQRoEl85H9PLbE4CsD9GZqeQ4`